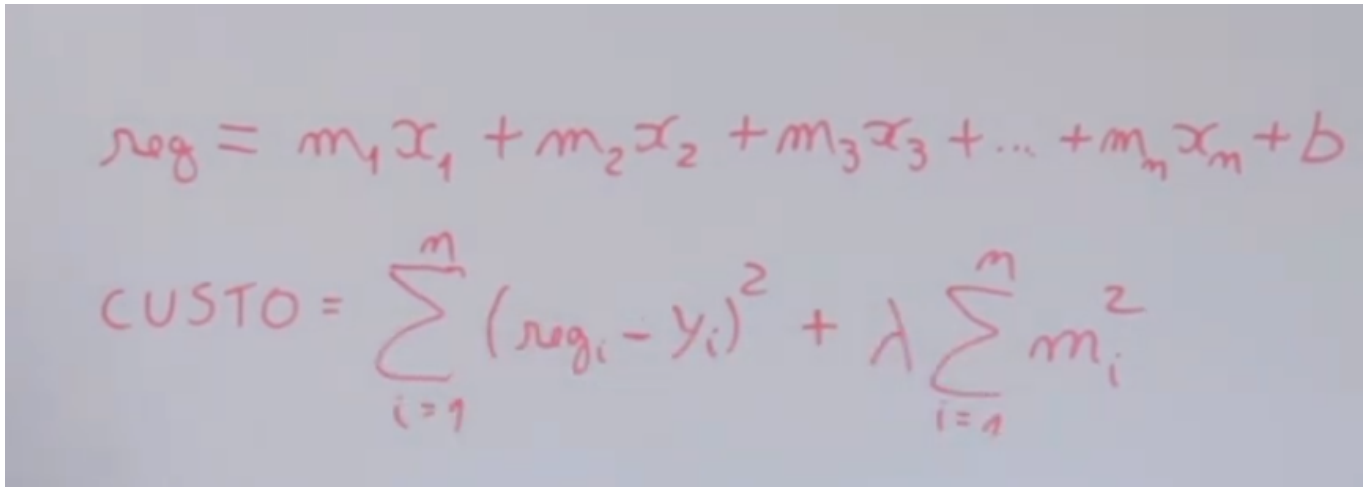


Ridge e Lasso Regression

A função de custo é diferente de uma regressão linear simples ou múltipla. Ela possui uma constante normalizadora que é multiplicada pelo somatório de todos os pesos elevado ao quadrado.



The image shows two handwritten equations in red ink on a light blue background. The first equation is the linear regression model:
$$reg = m_1 x_1 + m_2 x_2 + m_3 x_3 + \dots + m_n x_n + b$$
 The second equation is the cost function for Ridge and Lasso regression:
$$CUSTO = \sum_{i=1}^n (reg_i - y_i)^2 + \lambda \sum_{i=1}^n m_i^2$$

Queremos encontrar o menor erro desde que os valores de cada coeficiente sejam menores. Ou seja, se tivermos um coeficiente muito grande, ao elevar ao quadrado ele receberá muito peso, portanto o algoritmo adapta os valores dos coeficientes para ficarem mais próximos e mantendo o erro menor possível.

**Impedir que uma variável recebe muito mais peso que as outras, ou seja
"REGULARIZAÇÃO"**

Mas para quê usar?

A função de custo da regressão linear é feita na base de treino, ou seja minimizamos o erro da reta baseado nos dados de treino, porém é necessário deixar o modelo mais generalizável para não causar overfitting, por isso é interessante regularizar os termos para que variáveis não recebam um peso maior do que deveriam durante o treinamento do modelo. O modelo desconfia dos pesos das variáveis.

Exemplo:

$$\text{reg} = m_1 x_1 + m_2 x_2 + m_3 x_3 + \dots + m_n x_n + b$$

$$\text{CUSTO}_{\text{RIDGE}} = \sum_{i=1}^n (\text{reg}_i - y_i)^2 + \lambda \sum_{i=1}^n m_i^2$$

$$m_1 = 1$$

$$m_2 = 4$$

$$\boxed{\begin{matrix} m_1 = 2 \\ m_2 = 3 \end{matrix}}$$

$$(1^2 + 4^2) = 17$$

$$(2^2 + 3^2) = 13$$

Veja que ao aproximar m_1 de m_2 , o custo pode ter ficado um pouco pior, porém mais regularizado com os pesos dos coeficientes de 17 para 13.

Derivada

$$(y_i - y_i)^2 + \lambda \sum_{i=1}^n m_i^2$$

$$\frac{\partial \lambda (m_1^2 + m_2^2 + m_3^2 + \dots)}{\partial m_1}$$

$$\lambda \cdot 2m_1$$

Ao realizar a derivada do termo em relação a m_1 por exemplo, ficaria constante $2m_1$, pois todo o somatório ficaria constante, restando apenas m_1 elevado ao quadrado, e a derivada disso é $2m_1$.

Colabora com a colinearidade, mantendo os pesos na mesma ordem de grandeza. Ou seja Correlação de Pearson

A FUNÇÃO RIDGE UTILIZA A REGULARIZAÇÃO **L2** NA REGRESSÃO LINEAR. O TERMO L2 SE DEVE AO ELEVAR TODOS OS COEFICIENTES AO QUADRADO FAZENDO COM QUE HAJA A REGULARIZAÇÃO DOS PESOS DE CADA VARIÁVEL.

JÁ A FUNÇÃO L1 É O MÓDULO DOS COEFICIENTES, UTILIZADA NA FUNÇÃO LASSO. ELA TEM O MESMO OBJETIVO DE MINIMIZAR OS TERMOS, PORÉM MENOS RÍGIDA QUE A L2, TENDO UM PESO MENOR.

REGRESSÃO LASSO:

$$\text{CUSTO} = \sum_{i=1}^m (\log_i - y_i)^2 + \sum_{i=1}^m |m_i|$$